Desarrollo de un prototipo de gemelo digital comunitario para vivienda social y evaluación computacional con datos mixtos

Development of a community digital twin prototype for social housing and computational evaluation with mixed data

Bardales Leon, Anthony Daniel; Rodríguez Silva, José Aaron

Universidad Nacional de Trujillo, Guadalupe, Perú

Resumen

El estudio presenta el desarrollo de un prototipo de gemelo digital comunitario orientado a explorar escenarios de vivienda social y una evaluación computacional de su módulo de aprendizaje automático. Se integraron componentes de visualización 2D/3D, representación de escenarios, deliberación y evaluación multicriterio. El experimento empleó 8.028 registros de manzanas de San Juan de Lurigancho, con conteos censales de población, hogares y viviendas y atributos territoriales simulados. El valor del suelo utilizado como objetivo fue generado mediante una fórmula explícita y no corresponde a precios observados de mercado. Se compararon Random Forest, Gradient Boosting, XGBoost, LightGBM y CatBoost mediante cinco particiones aleatorias en 6.422 registros de desarrollo y un conjunto independiente de 1.606 registros de prueba. CatBoost obtuvo el menor RMSE medio de validación. En prueba alcanzó $R^2 = 0,7392$, RMSE = 91,56 USD/m² y MAE = 68,49 USD/m²; el intervalo bootstrap del 95 % para el RMSE fue [87,32; 95,97]. Estos resultados describen la recuperación de relaciones del generador sintético y permiten comprobar el flujo de entrenamiento, selección y evaluación. No constituyen una validación inmobiliaria, espacial ni participativa. La contribución es un prototipo y un experimento reproducible que delimitan los requisitos para una posterior evaluación con datos georreferenciados observados y residentes.

Palabras clave: prototipo de gemelo digital; simulación urbana; aprendizaje automático; datos sintéticos; vivienda social; reproducibilidad.

Abstract

This study presents the development of a community digital twin prototype intended to explore social housing scenarios and a computational evaluation of its machine learning module. The prototype integrates 2D/3D visualization, scenario representation, deliberation, and multicriteria assessment components. The experiment used 8,028 census-block records from San Juan de Lurigancho, combining census counts of population, households, and dwellings with simulated territorial attributes. The land value target was generated through an explicit formula and does not represent observed market prices. Random Forest, Gradient Boosting, XGBoost, LightGBM, and CatBoost were compared using five random folds within 6,422 development records and an independent test set of 1,606 records. CatBoost achieved the lowest mean validation RMSE. Its test performance was $R^2 = 0.7392$, RMSE = 91.56 USD/m², and MAE = 68.49 USD/m²; the 95% bootstrap interval for RMSE was [87.32, 95.97]. These findings describe recovery of relationships embedded in the synthetic generator and support verification of the training, selection, and evaluation workflow. They do not constitute real-estate, spatial, or participatory validation. The contribution is a prototype and a reproducible experiment that identify requirements for subsequent evaluation with observed georeferenced data and residents.

Keywords: digital twin prototype; urban simulation; machine learning; synthetic data; social housing; reproducibility.

1 Introducción

Los gemelos digitales urbanos ofrecen entornos para representar componentes de una ciudad, explorar intervenciones y comunicar alternativas a distintos actores. El prototipo de Herrenberg muestra una aplicación de estas capacidades a la planificación y visualización urbana (Dembski et al., 2020). White et al. (2021) incorporan un mecanismo de retroalimentación ciudadana sobre cambios proyectados. Estos antecedentes vinculan representación digital y participación, aunque la disponibilidad de una interfaz no demuestra, por sí sola, que los residentes comprendan sus resultados o influyan en las decisiones.

En vivienda social, la comparación de escenarios requiere distinguir tres clases de información: características observadas del territorio, supuestos de simulación y preferencias expresadas por las personas. Mezclarlas puede atribuir a un indicador calculado una autoridad que sus datos no justifican. La integración social de los gemelos digitales exige considerar las relaciones entre representación, actores y procesos de decisión, además del funcionamiento técnico (Qanazi et al., 2025).

Este trabajo aborda una etapa de desarrollo tecnológico previa a la evaluación con residentes. Su objetivo es describir un prototipo que reúne visualización, escenarios y herramientas de comparación, y evaluar de forma reproducible el componente de aprendizaje automático en un entorno de datos mixtos. La aplicación se contextualiza en San Juan de Lurigancho, Lima, pero el experimento predictivo utiliza atributos territoriales y valores del suelo simulados. Por tanto, su alcance es computacional y no una estimación empírica del mercado inmobiliario distrital.

Se plantean dos preguntas: ¿cómo organizar el prototipo para separar datos, reglas de evaluación y módulos de interacción?, y ¿qué desempeño presentan cinco modelos de ensamble al recuperar una variable sintética bajo un procedimiento común de evaluación? La primera se aborda mediante la descripción de la arquitectura y sus límites; la segunda, mediante un experimento con separación entre desarrollo y prueba. La usabilidad, la inclusión digital y la incidencia comunitaria se reservan para una evaluación posterior y no se presentan como resultados alcanzados.

2 Antecedentes y contribución

Los trabajos de Dembski et al. (2020) y White et al. (2021) sustentan la utilidad de estudiar conjuntamente representación urbana e interacción. Qanazi et al. (2025) revisan la incorporación de dimensiones sociales y proponen un marco para gemelos digitales sociales. El presente prototipo retoma esa orientación como propósito de diseño; no pretende demostrar una ventaja participativa sobre esos sistemas ni sustituir sus procesos de evaluación.

Tabla 1. Relación con antecedentes y alcance de la contribución

Antecedente	Componente pertinente	Alcance del presente estudio
Dembski et al. (2020)	Representación y visualización de un gemelo urbano para planificación.	Integra una representación de escenarios y un módulo predictivo experimental.
White et al. (2021)	Retroalimentación ciudadana sobre cambios urbanos.	Incluye componentes de deliberación; su uso por residentes no se evalúa aquí.
Qanazi et al. (2025)	Integración conceptual de dimensiones sociales.	Distingue el objetivo comunitario de la validación técnica realizada.

Para el componente predictivo se emplean familias consolidadas de ensambles. Random Forest combina árboles de decisión (Breiman, 2001); XGBoost incorpora procedimientos de optimización y regularización (Chen y Guestrin, 2016); LightGBM introduce mejoras para entrenar árboles con eficiencia (Ke et al., 2017); y CatBoost desarrolla técnicas de boosting y tratamiento de variables categóricas (Prokhorenkova et al., 2018). En este experimento todas las variables categóricas se codifican

mediante one-hot antes del estimador, incluido CatBoost. En consecuencia, no se evalúa la ventaja específica de su tratamiento nativo de categorías.

La contribución no consiste en un algoritmo nuevo. Consiste en integrar componentes de software para explorar escenarios, documentar la separación entre observación y simulación y proporcionar un procedimiento verificable de comparación. Un buen ajuste a la variable sintética indica que el estimador recupera relaciones presentes en el generador; no demuestra causalidad, validez territorial o capacidad de tasación.

3 Metodología

3.1 Diseño y alcance

Se realizó un estudio de desarrollo tecnológico acompañado de un experimento computacional. La unidad de registro es la manzana identificada en el archivo censal de referencia. No se reclutaron participantes, no se realizaron talleres y no se evaluaron decisiones reales de vivienda. El término prototipo de gemelo digital describe la orientación del sistema: la versión evaluada no acredita sincronización continua con el territorio ni retroalimentación operativa desde intervenciones físicas.

El proceso se organiza según las seis fases de CRISP-DM: comprensión del problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (IBM, s. f.). La comprensión del problema delimitó el uso experimental; la comprensión y preparación separaron conteos de atributos generados; el modelado comparó cinco estimadores; la evaluación utilizó particiones comunes y análisis de incertidumbre; y el despliegue corresponde a la integración local del módulo en el prototipo, sin afirmar una implantación municipal.

3.2 Arquitectura e implementación

La aplicación utiliza Python y Streamlit para la interfaz; Three.js y componentes cartográficos para la representación 3D y 2D; pandas y NumPy para el manejo de datos; y bibliotecas de aprendizaje automático para el entrenamiento local. Los escenarios se almacenan en archivos JSON y la base experimental en CSV. La arquitectura revisada no requiere PostGIS para ejecutar el experimento. La presencia de ejemplos de infraestructura en una sección de la interfaz no equivale a una base espacial desplegada.

Tabla 2. Componentes del prototipo y límites de la evidencia

Componente	Función implementada en el código	Límite de la evaluación
Representación	Visualización 2D/3D y selección de escenarios.	No se cuantifica exactitud geométrica ni fidelidad topográfica.
Escenarios e indicadores	Conteos, costos agregados e indicadores calculados mediante reglas.	Los índices ambientales y de accesibilidad son heurísticos; no son mediciones de campo.
Deliberación	Interfaz para propuestas y distribución de presupuesto.	No existen resultados de participación real en este estudio.
Evaluación multicriterio	Ponderación de criterios y comparación de escenarios.	Su implementación y sensibilidad requieren validación específica.
Aprendizaje automático	Preprocesamiento, entrenamiento, selección, prueba y exportación.	Evaluado con un objetivo sintético, sin validación geográfica externa.

El cálculo de indicadores y el modelo predictivo son componentes distintos. La estimación de valor del suelo no valida automáticamente indicadores de accesibilidad, riesgo, confort o calidad de vida. En

particular, las distancias y tiempos simplificados no deben interpretarse como un análisis completo de rutas peatonales. La explicación de predicciones mediante SHAP o LIME puede explorarse posteriormente; no se atribuyen resultados de estos métodos al experimento presentado.

3.3 Datos y trazabilidad

La fuente censal declarada es el sistema REDATAM del INEI para los Censos Nacionales 2017, que permite consultar información de población y vivienda (INEI, 2024). Se utilizó una exportación titulada "SJL – Población, viviendas y hogares por manzana – 2017". La comprobación fila a fila confirmó que el archivo experimental conserva los 8.028 identificadores y los tres conteos del Excel de origen. Los totales son 314.581 viviendas, 274.657 hogares y 1.038.495 habitantes. Esta comprobación verifica la consistencia entre archivos, sin constituir una nueva consulta independiente al servicio del INEI.

El CSV contiene 23 columnas, 8.028 identificadores únicos y ningún valor faltante. Sus registros están etiquetados como datos mixtos. Los conteos se complementaron con atributos generados mediante una semilla de 20261017. La asignación a perfiles consolidados, intermedios y de ladera fue aleatoria, con probabilidades de 0,40, 0,38 y 0,22; no se infirió a partir de la ubicación real de cada manzana.

Tabla 3. Procedencia de las variables del experimento

Grupo	Variables	Procedencia y uso
Conteos	Viviendas, hogares y población.	Conservados de la exportación censal; incluidos como predictores.
Identificación	Código de manzana, distrito, ciudad, año y tipo de datos.	Metadatos; excluidos como identificadores o constantes.
Atributos simulados	Área de lote, distancias a vías, salud y escuela; pendiente; vulnerabilidad; área verde; estrato; material y antigüedad.	Generados por perfiles y distribuciones; incluidos como predictores.
Variables mixtas	Área de manzana y densidad.	Área simulada a partir de viviendas; densidad calculada con población y área simulada.
Objetivo	valor_suelo_usd_m2.	Resultado de una fórmula sintética; no observado en el mercado.
Otros resultados	Viabilidad y riesgo de deslizamiento.	Generados; excluidos de los predictores para reducir el uso de resultados derivados.

El nombre heredado indice_vulnerabilidad_cenepred no convierte esa columna en un indicador oficial de CENEPRED: sus valores fueron simulados. Tampoco se utilizaron capas GHSL, indicadores observados de ONU-Hábitat o valores catastrales como fuentes efectivas de entrenamiento en esta ejecución. Los elementos cartográficos de la interfaz no acreditan una vinculación geográfica de las filas del CSV.

3.4 Generación de la variable objetivo

La variable objetivo se construyó en la escala nominal USD/m² mediante la siguiente regla, implementada en el script de preparación:

$$y = \text{redondear}_2\{\text{limitar}[(500 - 5s - 0{,}11d - 1{,}1v + 9g + b_e) \times \exp(\varepsilon), 35, 1100]\}.$$

En la expresión, s es la pendiente simulada, d la distancia simulada a la vía principal, v el índice de vulnerabilidad simulado y g el área verde simulada por habitante. El término b_e toma los valores −45, 0, 90 y 200 para los estratos Muy Bajo, Bajo, Medio y Medio Alto. El error ε se genera con una distribución normal de media 0 y desviación estándar 0,22. limitar restringe el resultado al intervalo [35; 1100] y redondear_2 conserva dos decimales. El generador usa la pendiente antes del redondeo con que se

exporta al CSV; la reproducción exacta requiere ejecutar el script original y respetar el orden de las llamadas aleatorias.

Los coeficientes son supuestos del generador y no parámetros estimados con transacciones. La media del objetivo es 383,93 y su rango es [35; 1100]. La unidad nominal se mantiene para describir la simulación, sin interpretar los valores como precios actualizados. El diseño incorpora relaciones entre los predictores y el objetivo de forma deliberada; por ello, el ajuste de los modelos mide principalmente la recuperación de esas relaciones.

3.5 Preparación y comparación de modelos

La nueva ejecución del 25 de octubre de 2026 utilizó 15 predictores. Se excluyeron identificadores, columnas constantes, la variable objetivo y las dos salidas derivadas de viabilidad y riesgo. Se reservó el 20 % de las observaciones como prueba final: 1.606 registros; los 6.422 restantes conformaron el conjunto de desarrollo. La partición aleatoria utilizó la semilla 42. Dentro del desarrollo se aplicó KFold de cinco particiones con mezcla aleatoria y la misma semilla. Todos los modelos utilizaron los mismos índices.

El preprocesamiento forma parte del pipeline de cada ajuste. Las variables numéricas se imputan mediante la mediana y las categóricas mediante la moda y codificación one-hot, ignorando categorías desconocidas al predecir. Aunque el CSV no contiene ausencias, este diseño evita que futuras imputaciones utilicen información del conjunto de prueba. En cada partición, los transformadores se ajustan exclusivamente con las observaciones de entrenamiento.

Se utilizó una configuración fija por familia, definida antes de consultar los resultados de prueba: 150 árboles o iteraciones, profundidad máxima de 6 y tasa de aprendizaje 0,05 para boosting. No se realizó búsqueda de hiperparámetros. La selección del modelo de referencia se basó en el menor RMSE medio de validación dentro del desarrollo; posteriormente cada modelo se reajustó con los 6.422 registros y se evaluó una vez en el conjunto reservado. Se añadió un predictor constante igual a la media del objetivo en desarrollo como línea base.

Tabla 4. Configuración principal de los estimadores

Estimador	Parámetros explícitos	Tratamiento común
Random Forest	n_estimators=150; max_depth=6; random_state=42; n_jobs=2.	Imputación y one-hot dentro del pipeline.
Gradient Boosting	n_estimators=150; max_depth=6; learning_rate=0,05; random_state=42.	Estimador estándar; sin redes de grafos ni estructura espacial.
XGBoost	n_estimators=150; max_depth=6; learning_rate=0,05; random_state=42; n_jobs=2.	La prueba final no interviene en el ajuste.
LightGBM	n_estimators=150; max_depth=6; learning_rate=0,05; random_state=42; n_jobs=2.	Mismas particiones y predictores.
CatBoost	iterations=150; depth=6; learning_rate=0,05; random_seed=42; thread_count=2.	Entrada ya codificada; sin categorías nativas.

Los parámetros no modificados corresponden a los valores por defecto de las versiones registradas y se exportan completos en resultados.json. El entorno utilizó Python 3.12.14, numpy 2.3.5, pandas 3.0.1, scikit-learn 1.9.1, scipy 1.18.1, catboost 1.2.10, lightgbm 4.7.0, xgboost 3.4.1, matplotlib 3.11.2. Esta configuración permite comparar implementaciones concretas; no representa una optimización exhaustiva ni un presupuesto equivalente de complejidad entre familias.

3.6 Métricas e incertidumbre

Se calcularon R^2, RMSE y MAE a partir de las mismas referencias y predicciones de prueba. R^2 se define como $1 - \Sigma(y - \hat{y})^2/\Sigma(y - \bar{y})^2$; RMSE como la raíz de la media de $(y - \hat{y})^2$; y MAE como la media de $|y - \hat{y}|$. Las métricas de error se expresan en la escala nominal USD/m² y R^2 no tiene unidades.

Se estimaron intervalos percentiles del 95 % mediante 2.000 remuestras bootstrap de los 1.606 pares referencia–predicción, con semilla 20261025 y los mismos índices para todos los modelos. Los intervalos son condicionales a los modelos ajustados y a la muestra sintética; no incluyen la variabilidad de volver a entrenar, de elegir otra semilla de generación ni de cambiar los supuestos del generador.

Como análisis exploratorio, se compararon los errores absolutos del modelo seleccionado con los de las otras cuatro familias. Se calcularon diferencias pareadas de MAE, sus intervalos bootstrap y pruebas bilaterales de aleatorización por intercambio del signo de cada diferencia, con 10.000 permutaciones Monte Carlo. Se aplicó la corrección de Holm a las cuatro comparaciones. Estas pruebas presuponen intercambiabilidad bajo la hipótesis nula y no respaldan inferencias sobre población o territorio reales.

3.7 Alcance de la validación y reproducibilidad

La validación es aleatoria, no espacial. El CSV no contiene geometrías o coordenadas verificadas que permitan construir bloques geográficos contiguos. Agrupar por un identificador único de manzana no garantiza separación territorial. La evaluación con datos observados requerirá unir geometrías fiables, definir bloques y distancias de separación, y mantener esa estructura tanto en el ajuste como en la evaluación, conforme a las precauciones discutidas por Roberts et al. (2017).

El material complementario conserva el CSV evaluado, el código utilizado, las predicciones por observación, los índices de partición, los parámetros completos, las versiones y la huella SHA-256 del conjunto. Las métricas pueden recalcularse sin volver a entrenar. La ejecución se identifica por su fecha y configuración; no se presenta como una reproducción exacta de ejecuciones históricas.

4 Resultados

4.1 Verificación técnica

Los cinco modelos completaron las cinco particiones de desarrollo y el ajuste final, para un total de 30 ajustes de estimadores. La comprobación del archivo confirmó 8.028 registros completos y correspondencia de los tres conteos con el Excel de origen. Además, una suite de cinco pruebas automatizadas del módulo de experimentos finalizó correctamente. Estas pruebas cubren, entre otros aspectos, separación de particiones, selección compartida, aislamiento de la imputación y manejo de fallos; no equivalen a una evaluación integral de la plataforma ni a pruebas de usabilidad.

4.2 Desempeño en desarrollo y prueba

Tabla 5. Evaluación sobre 1.606 registros de prueba con intervalos bootstrap del 95 %

Modelo	R^2 [IC 95 %]	RMSE [IC 95 %]	MAE [IC 95 %]
CatBoost	0,7392 [0,7181; 0,7585]	91,56 [87,32; 95,97]	68,49 [65,62; 71,67]
LightGBM	0,7284 [0,7056; 0,7486]	93,44 [89,12; 97,88]	69,69 [66,74; 72,88]
Random Forest	0,7275 [0,7059; 0,7474]	93,61 [89,49; 98,05]	70,75 [67,97; 73,97]
Gradient Boosting	0,7239 [0,7012; 0,7446]	94,21 [89,94; 98,62]	70,11 [67,02; 73,29]
XGBoost	0,7234 [0,7004; 0,7437]	94,30 [90,05; 98,73]	70,45 [67,45; 73,71]
Media del entrenamiento	-0,000016 [-0,003320; -0,000001]	179,31 [172,92; 185,63]	144,72 [139,56; 150,21]

Nota. RMSE y MAE se expresan en USD/m² de la simulación. La tabla se ordena por RMSE de prueba para facilitar la lectura; la selección se efectuó previamente con la validación de desarrollo. Los intervalos corresponden al remuestreo de observaciones de prueba con modelos fijos.

Los RMSE medios de validación fueron CatBoost: 92,13; LightGBM: 94,10; Random Forest: 94,12; Gradient Boosting: 94,23; XGBoost: 94,73. CatBoost fue el modelo de referencia seleccionado. En prueba redujo el RMSE en 1,88 unidades frente a LightGBM, aproximadamente un 2,01 %, y presentó un error considerablemente menor que la línea base constante. La magnitud de la ventaja entre ensambles es pequeña en relación con el error absoluto del problema simulado.

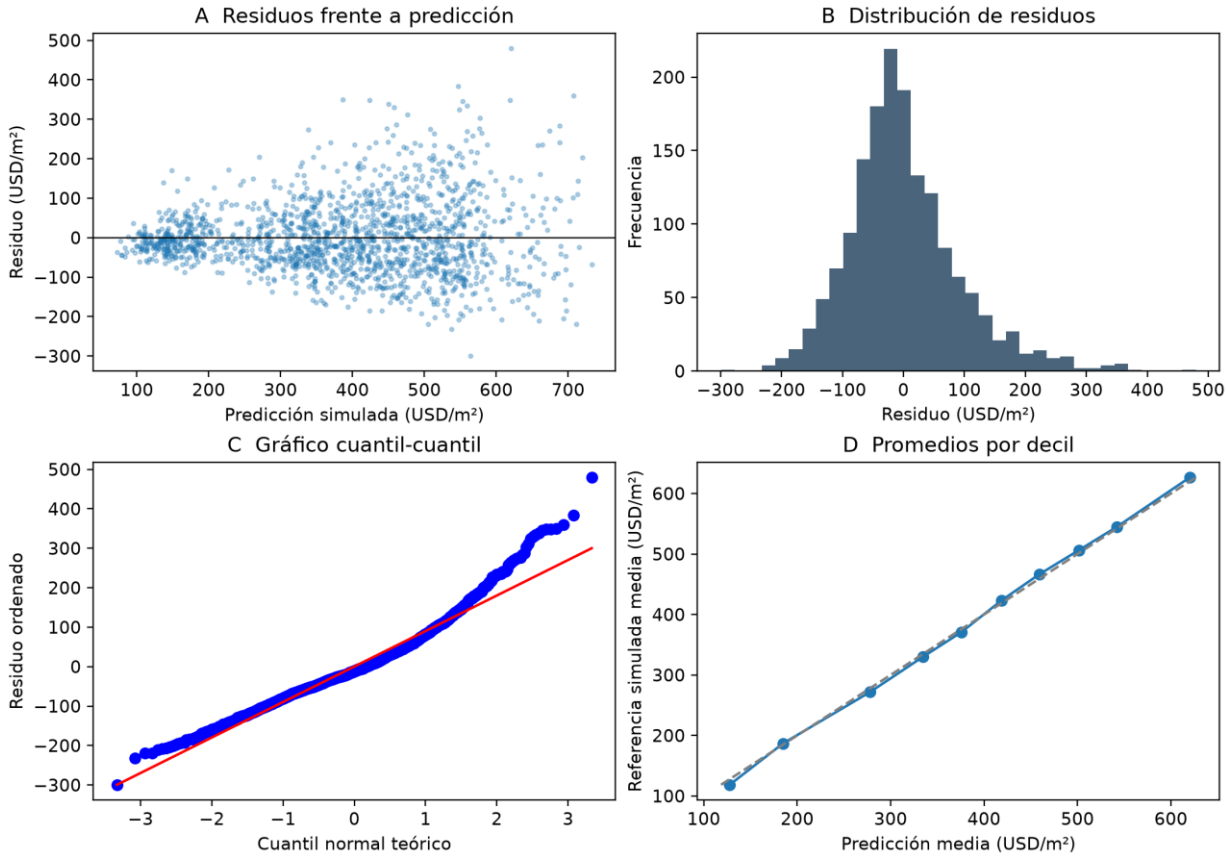
Tabla 6. Comparaciones exploratorias pareadas con CatBoost

Comparación	Δ MAE [IC 95 %]	p ajustado por Holm
CatBoost − Random Forest	-2,26 [-3,17; -1,31]	0,0004
CatBoost − Gradient Boosting	-1,63 [-2,58; -0,69]	0,0026
CatBoost − XGBoost	-1,96 [-2,88; -1,05]	0,0006
CatBoost − LightGBM	-1,20 [-2,04; -0,38]	0,0036

Nota. Un valor negativo de Δ MAE favorece a CatBoost en esta muestra. Los valores p se derivan de pruebas de aleatorización sobre errores absolutos y no de comparaciones de RMSE entre particiones. Aunque los cuatro contrastes arrojan p ajustado < 0,01, su interpretación queda limitada a los modelos fijos y al mecanismo sintético utilizado; no demuestra superioridad general ni relevancia para decisiones inmobiliarias.

4.3 Diagnóstico de errores

Figura 1. Diagnósticos de CatBoost en el conjunto de prueba



Nota. Residuo = referencia simulada − predicción. Los cuatro paneles se calcularon con las mismas 1.606 observaciones utilizadas en la Tabla 5. Elaboración propia.

La dispersión de residuos aumenta en los valores predichos más altos y el gráfico cuantil-cuantil muestra desviaciones en las colas, especialmente en la positiva. Este patrón es compatible con el ruido multiplicativo incluido en el generador. Los promedios por decil siguen aproximadamente la diagonal, pero esa correspondencia agregada no elimina los errores individuales ni prueba calibración fuera de la distribución simulada. No se presupone normalidad de los residuos para calcular las métricas o los intervalos bootstrap.

5 Discusión

El experimento demuestra que el flujo de preparación, comparación y prueba produce resultados verificables bajo una configuración común. La mejora frente a la media de entrenamiento confirma que los predictores contienen información sobre el objetivo generado. Este hallazgo era esperable porque la fórmula del objetivo utiliza algunos de esos atributos. La comparación entre ensambles resulta útil para comprobar el módulo, pero no basta para afirmar una contribución novedosa en valoración del suelo.

La integración del prototipo ofrece una base para estudiar la relación entre escenarios, indicadores y preferencias. Sin embargo, la literatura sobre participación y gemelos digitales no autoriza a inferir beneficios sociales a partir del rendimiento predictivo (Dembski et al., 2020; White et al., 2021; Qanazi et al., 2025). La facilidad de uso por personas con baja alfabetización digital, la comprensión de la incertidumbre y la capacidad de modificar prioridades son hipótesis de diseño que necesitan observación directa.

La validez interna está limitada por una sola generación de datos, una sola partición final y configuraciones fijas. Los intervalos y contrastes no incluyen la variabilidad del reentrenamiento. La

validez de constructo se restringe porque los indicadores de vulnerabilidad, accesibilidad y valor son aproximaciones generadas. La validez externa es especialmente limitada: no se emplearon transacciones, avalúos independientes o atributos territoriales medidos, y no existe evaluación espacial o temporal fuera de la muestra.

La composición de datos requiere especial atención al comunicar resultados. Un nombre de columna asociado a una institución no acredita su procedencia oficial. Del mismo modo, la escala USD/m² no transforma una simulación en tasación. La interfaz debe mostrar la condición simulada de entradas y salidas, las reglas de cálculo y sus límites, de manera que una comparación de escenarios no se confunda con una recomendación normativa o una decisión automatizada sobre los residentes.

La ausencia de evaluación participativa delimita el alcance de la contribución. El estudio no mide representatividad, equidad en la deliberación, confianza, consenso o cambios en políticas. Tampoco acredita que una visualización 3D reproduzca fielmente la topografía o que un índice heurístico equivalga a una medición ambiental. Estos componentes requieren validación independiente antes de emplearse en decisiones de inversión, seguridad o planificación.

6 Plan de evaluación posterior

La siguiente fase deberá separar validación territorial y evaluación con usuarios. Para la primera, se requiere una base de precios observados que identifique fuente, fecha, unidad, localización y tipo de registro; los precios de oferta deberán distinguirse de transacciones o avalúos. Las geometrías de manzana deberán vincularse mediante identificadores verificados. El protocolo definirá bloques geográficos, un conjunto externo y, si procede, separación temporal antes del ajuste de hiperparámetros. También deberá comparar resultados con modelos de referencia e incluir análisis de sensibilidad a las variables simuladas que se sustituyan.

Para la evaluación con residentes se propone un estudio piloto de factibilidad, seguido de una evaluación comparativa cuyo tamaño muestral se determine a partir del desenlace principal y la variabilidad del piloto. Las tareas incluirán localizar un servicio, modificar un escenario, interpretar un indicador y expresar una preferencia. Se registrarán éxito por tarea, tiempo, errores, ayuda requerida y comprensión de la condición simulada de los resultados. Una comparación posterior podrá utilizar un procedimiento convencional de mapas y fichas como referencia, con asignación o contrabalanceo previamente definidos.

La selección deberá explicitar edad, residencia, experiencia digital y necesidades de accesibilidad; la baja alfabetización digital no se inferirá a partir del ingreso. Se establecerán consentimiento informado, resguardo de datos y la revisión institucional aplicable antes del reclutamiento. Las entrevistas sobre comprensión y deliberación complementarán los resultados cuantitativos. El piloto permitirá ajustar instrumentos, pero no se utilizará por sí solo para afirmar efectos comunitarios generalizables.

7 Conclusiones

Se desarrolló un prototipo orientado a la exploración de escenarios de vivienda social y se evaluó su módulo predictivo mediante un experimento reproducible con 8.028 registros mixtos. La trazabilidad distingue conteos censales conservados de atributos y objetivos simulados. CatBoost presentó el menor RMSE medio de validación y alcanzó $R^2 = 0{,}7392$, RMSE = 91,56 y MAE = 68,49 en el conjunto independiente de prueba, bajo la configuración estudiada.

Estos resultados respaldan el funcionamiento del procedimiento de entrenamiento y evaluación en un entorno sintético. No permiten afirmar precisión inmobiliaria real, generalización espacial, eficacia del co-diseño ni accesibilidad para residentes. La contribución establece una base técnica documentada y delimita las verificaciones necesarias para avanzar hacia una plataforma territorial y participativa evaluada con evidencia observada.

Declaraciones

Uso de inteligencia artificial

Se utilizaron Claude para apoyar la reorganización y redacción del manuscrito, Consensus como apoyo a la búsqueda bibliográfica y Antigravity y Google AI Studio para asistir en la construcción del código. En la revisión se utilizó Codex para auditar archivos, preparar una nueva ejecución computacional y editar el texto. Las métricas proceden de la ejecución de algoritmos sobre los archivos documentados. La selección de fuentes, la interpretación científica, la comprobación del código y la aprobación de la versión final son responsabilidad de los autores. Estas herramientas no figuran como autoras.

Financiación y conflictos de intereses

El estudio no recibió financiación externa. Los autores declaran no tener conflictos de intereses.

Disponibilidad de código y datos

El material complementario incluye los archivos del experimento, las predicciones y su configuración. El repositorio del proyecto indicado por los autores es https://github.com/lava-reefnotw2/digitaltwininmobiliario. La publicación de una versión archivada con identificador persistente y licencias explícitas de código y datos forma parte de las acciones de disponibilidad pendientes; no se declara un DOI ni una licencia todavía no formalizados.

Referencias

Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32. https://doi.org/10.1023/A:1010933404324

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Dembski, F., Wössner, U., Letzgus, M., Ruddat, M., & Yamu, C. (2020). Urban digital twins for smart cities and citizens: The case study of Herrenberg, Germany. Sustainability, 12(6), 2307. https://doi.org/10.3390/su12062307

IBM. (s. f.). CRISP-DM help overview. IBM Documentation. https://www.ibm.com/docs/en/spss-modeler/saas?topic=dm-crisp-help-overview

Instituto Nacional de Estadística e Informática. (2024, 7 de febrero). Consultar base de datos de los censos nacionales 2017 – Redatam. Plataforma del Estado Peruano. https://www.gob.pe/24120-consultar-base-de-datos-de-los-censos-nacionales-2017-redatam

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30. https://proceedings.neurips.cc/paper_files/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. Advances in Neural Information Processing Systems, 31. https://proceedings.neurips.cc/paper/7898-catboost-unbiased-boosting-with-categorical-features.pdf

Qanazi, S., Leclerc, E., & Bosredon, P. (2025). Integrating social dimensions into urban digital twins: A review and proposed framework for social digital twins. Smart Cities, 8(1), 23. https://doi.org/10.3390/smartcities8010023

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. Ecography, 40(8), 913–929. https://doi.org/10.1111/ecog.02881

White, G., Zink, A., Codecá, L., & Clarke, S. (2021). A digital twin smart city for citizen feedback. Cities, 110, 103064. https://doi.org/10.1016/j.cities.2020.103064